Raport 1. ZML - Regresja logistyczna

Monika Nowak

2026-02-25

Analiza danych

Rozważmy zbiór danych pochodzący z pliku `Lista_1.csv`, który opisuje relacje między prawdopodobieństwami przyjęcia na studia a wynikami testów rachunkowych i poziomu niepewności uczniów.

1. Załadowanie danych

Pobierzmy wymagany plik i sprawdźmy wygląd początkowych rekordów.

```
dane <- read.csv("lista_1.csv", row.names = 1)

head(dane)
```

```
##   numeracy anxiety success
## 1      6.6    13.8       0
## 2      7.1    14.6       0
## 3      7.3    17.4       0
## 4      7.5    14.9       1
## 5      7.9    13.4       0
## 6      7.9    13.5       1
```

Pierwsza kolumna przechowywanej w pliku tabeli stanowi numerację kolejnych wierszy. Dalej, kolumna `numeracy` przechowuje wynik testów rachunkowych, `anxiety` - poziom niepewności i `success` informuje o tym, czy dana osoba została przyjęta na studia (wartość 1), czy też nie (wartość 0).

2. Rysowanie boxplotów dla wyników testu rachunkowego

Przeanalizujmy boxploty dla zmiennej `numeracy` w rozbiciu na grupę przyjętych i nieprzyjętych osób.

Wykres

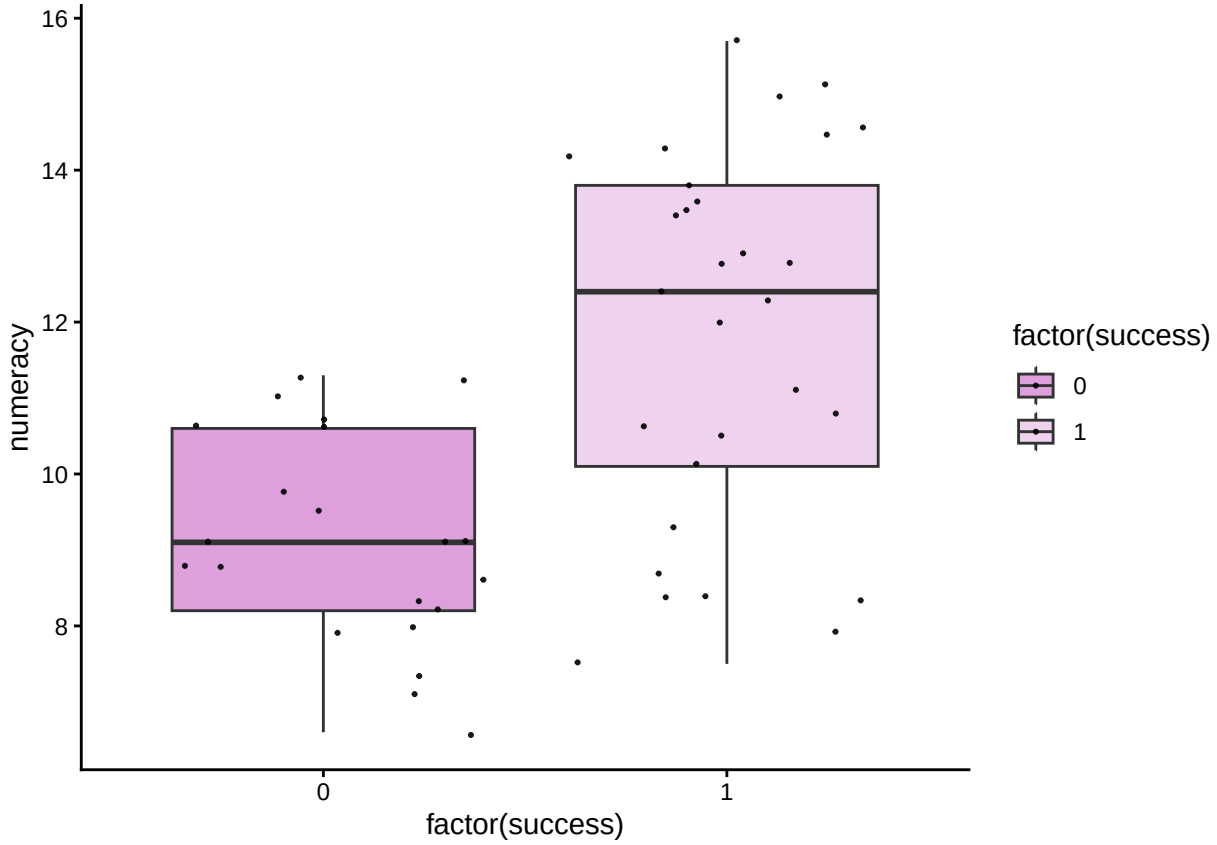
16
14
12
10
8
numeracy
0
1
factor(success)
factor(success)
0
1

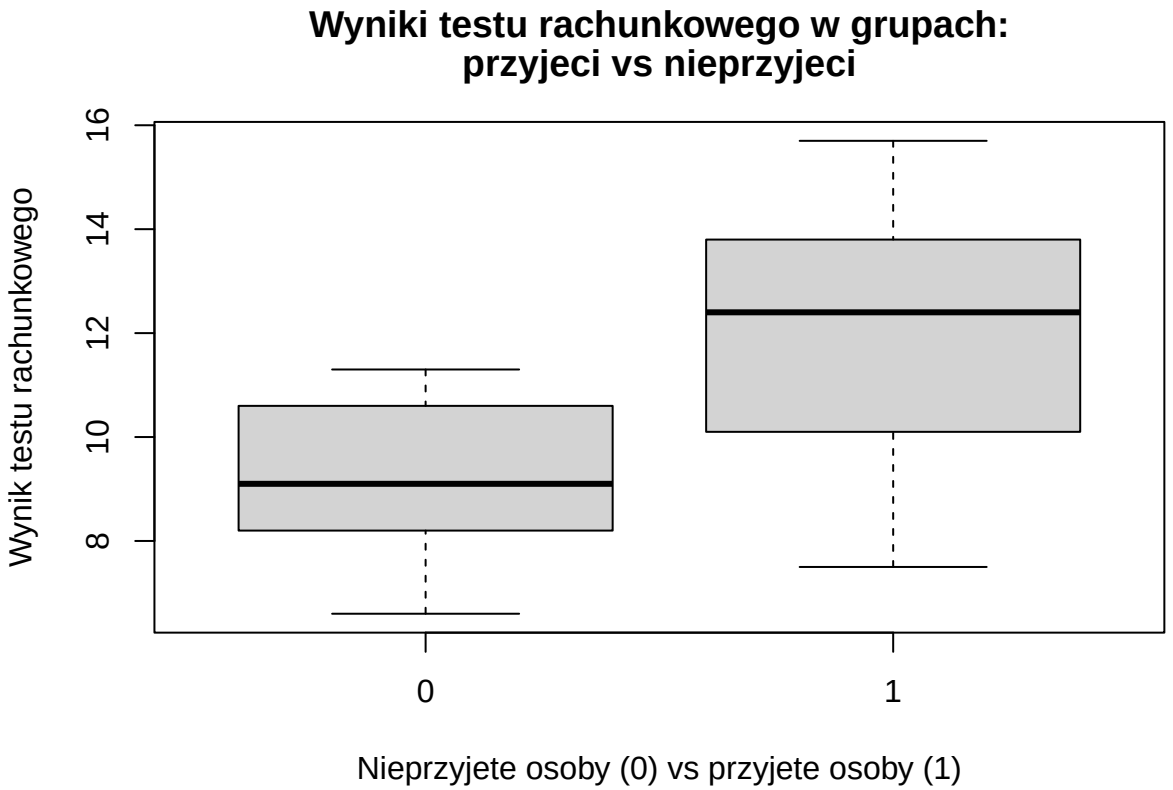
Wyniki testu rachunkowego w grupach:
przyjeci vs nieprzyjeci
Wynik testu rachunkowego
8
10
12
14
16
0
1
Nieprzyjete osoby (0) vs przyjete osoby (1)

Wnioski

W oparciu o zamieszczony wykres `Wyniki testu rachunkowego w grupach: przyjęci vs nieprzyjęci` możemy wyciągnąć wniosek, jakoby wynik testu rachunkowego był w sposób znaczny skorelowany z decyzją o przyjęciu kandydata na studia, o czym świadczy, że każda z cech rozkładu, to znaczy wartości minimalne i maksymalne oraz kwartyle są mniejsze w przypadku grupy osób nieprzyjętych w porównaniu do osób przyjętych.

3. Rysowanie boxplotów dla poziomu niepewności

Wykres

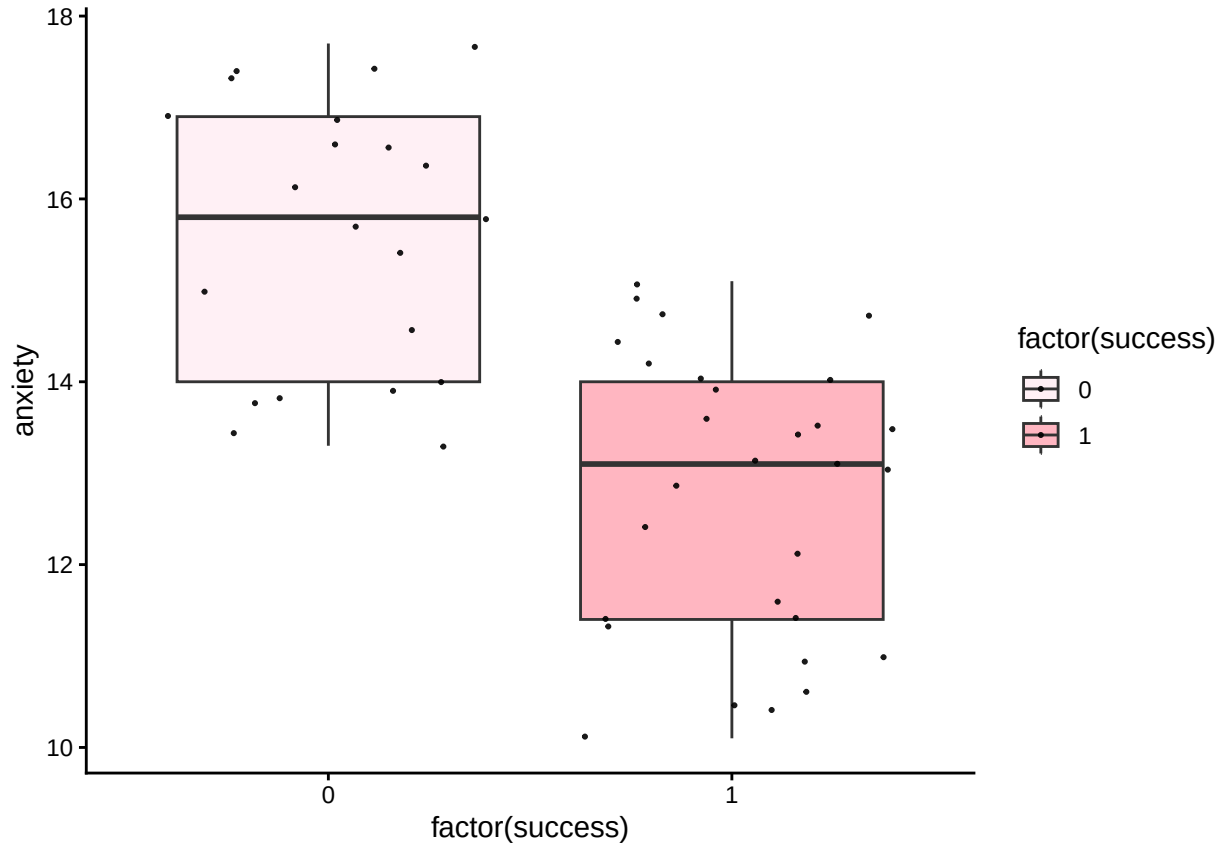

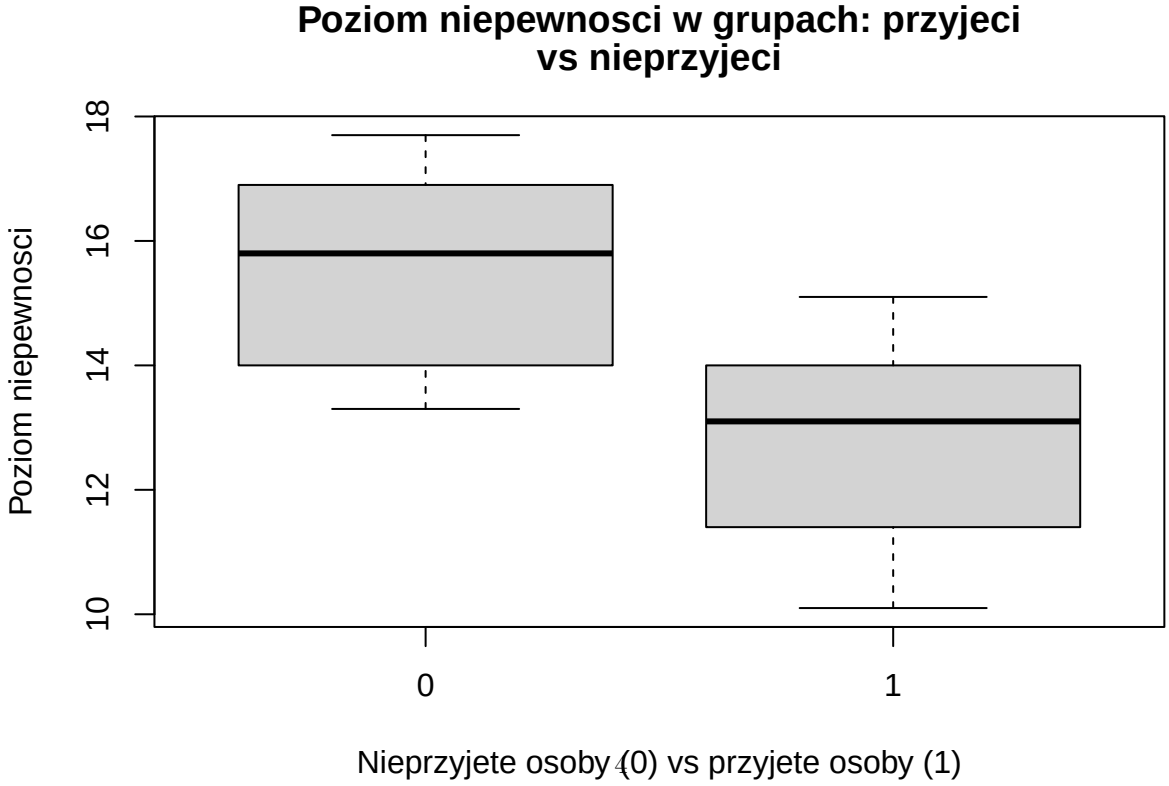

Wnioski

Porównując grupę nieprzyjętych i przyjętych osób na studia w zależności od rozkładu poziomu niepewności dochodzimy do konkluzji, iż ma on również silny wpływ na decyzję odnośnie przyjęcia. Grupa osób nieprzyjętych na studia cechuje się wyraźnie większymi odnotowaniami poziomów niepewności i każda cecha, tj. wartości minimalne i maksymalne oraz kwartyle, jest większa w porównaniu do wyników otrzymanych w grupie osób przyjętych.

4. Model regresji logistycznej

Konstrukcja modelu

Skontruujmy model regresji logistycznej oparty na danych pochodzących z pliku `Lista_1.csv`. W tym celu uzyjemy wbudowanej w `R` funkcji `glm`.

```
model <- glm(success ~ numeracy + anxiety, data = dane, family = binomial(link = "logit"))
```

Estymatory parametrów i wyniki testów istotności

Przeprowadźmy testowanie parametrów w regresji logistycznej dla hipotez zerowych takich, że kolejne parametry są równe zeru na poziomie istotności $\alpha = 0.05$. Wyniki przechowuje tabela `Estymatory parametrów i poziomy istotności`.

Table 1: Estymatory parametrów i poziomy istotności

	Estymator parametru	p-wartość
β_0	14.238581	0.0362275
wynik testu rachunkowego	0.577352	0.0199523
poziom niepewności	-1.384069	0.0039634

Na poziomie istotności $\alpha = 0.05$ mamy podstawy do odrzucenia hipotezy zerowej w przypadku każdego z parametrów. Oznacza to, że każdy z nich możemy uznać za istotny.

Predykcja sukcesu dla danego poziomu niepewności i wyniku testu rachunkowego

```
##         1
## 0.8827987
```

Wymodelowane prawdopodobieństwo dostania się na studia ucznia o zadanym poziomie niepewności i wyniku testu rachunkowego wynosi w przybliżeniu 88%. Szansa na sukces jest więc wysoka.

Krzywa ROC

Naszkicujemy krzywą ROC, korzystając z funkcji wbudowanej w pakiet `pROC`.

a) logit

```
## Type 'citation("pROC")' for a citation.
```

```
##
## Dołączanie pakietu: 'pROC'

## Następujące obiekty zostały zakryte z 'package:stats':
##
##     cov, smooth, var

## Setting levels: control = 0, case = 1

## Setting direction: controls < cases
```

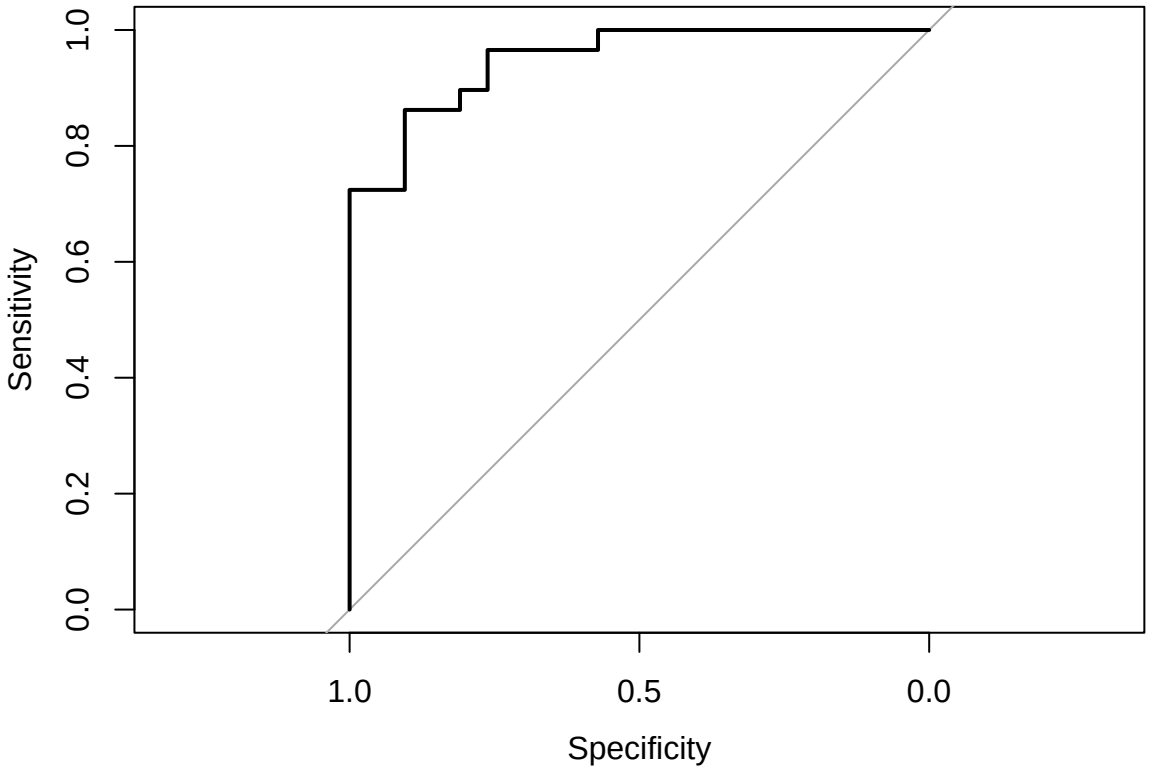

Istotnie odbiega ona od modelu liniowego, co świadczy o przewadze modelu regresji logistycznej.

a) probit

```
## Setting levels: control = 0, case = 1

## Setting direction: controls < cases
```

c) cauchit

```
## Setting levels: control = 0, case = 1

## Setting direction: controls < cases
```

c) cloglog

```
## Warning: glm.fit: dopasowane prawdopodobieństwa numerycznie okazały się być 0
## lub 1
```

```
## Setting levels: control = 0, case = 1
```

```
## Setting direction: controls < cases
```

Porównanie

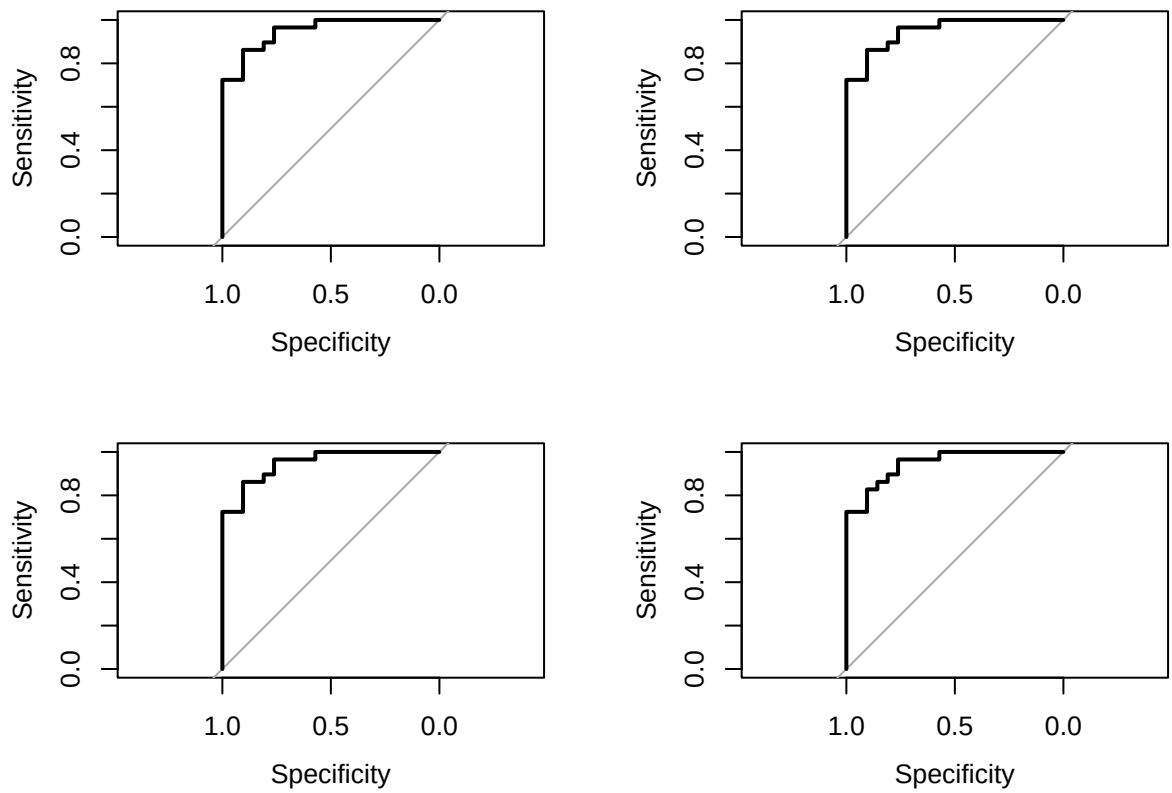


```
## [1] 1
```

```
## [1] 1
```

```
## [1] 0.4795001
```

```
## [1] 1
```

```
## [1] 0.4795001
```

```
## [1] 0.4795001
```

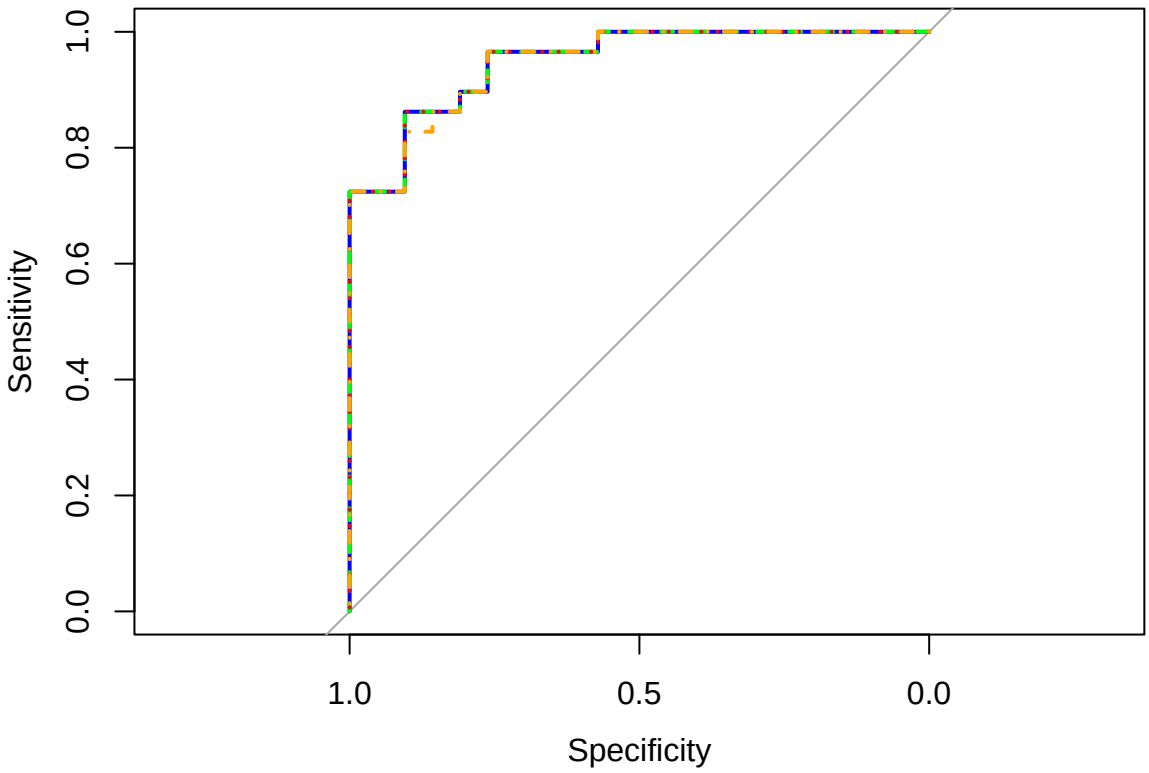

6. Model z funkcją linkującą "logit"

Estymator macierzy kowariancji

```
##             (Intercept)    numeracy     anxiety
## (Intercept)  46.2198633 -0.24830459 -3.06128454
## numeracy     -0.2483046  0.06154567 -0.02381546
## anxiety      -3.0612845 -0.02381546  0.23078671
```

Porównanie

```
##                    vcov           r
## (Intercept) 46.21986333 46.21986333
## numeracy     0.06154567  0.06154567
## anxiety      0.23078671  0.23078671
```