Raport 1. ZML - Regresja logistyczna

Monika Nowak

2026-02-25

Cel raportu

Celem raportu jest analiza danych przyjęć osób na studia z użyciem regresji logistycznej oraz przeprowadzenie symulacji ukazujących teoretyczne własności tego modelu.

Analiza danych

Rozważmy zbiór danych pochodzący z pliku `Lista_1.csv`, który opisuje relacje między decyzją odnośnie przyjęcia na studia a wynikami testów rachunkowych i poziomu niepewności uczniów.

1. Załadowanie danych

Pobierzmy wymagany plik i sprawdźmy wygląd początkowych rekordów.

```
dane <- read.csv("lista_1.csv", row.names = 1)

dane[1:3,]
```

```
##   numeracy anxiety success
## 1      6.6    13.8       0
## 2      7.1    14.6       0
## 3      7.3    17.4       0
```

Pierwsza kolumna przechowywanej w pliku tabeli stanowi numerację kolejnych wierszy. Dalej, kolumna `numeracy` przechowuje wynik testów rachunkowych, `anxiety` - poziom niepewności i `success` informuje o tym, czy dana osoba została przyjęta na studia (wartość 1), czy też nie (wartość 0).

2. Rysowanie boxplotów dla wyników testu rachunkowego

Przeanalizujmy boxploty dla zmiennej `numeracy` w rozbiciu na grupę przyjętych i nieprzyjętych osób.

Wykres

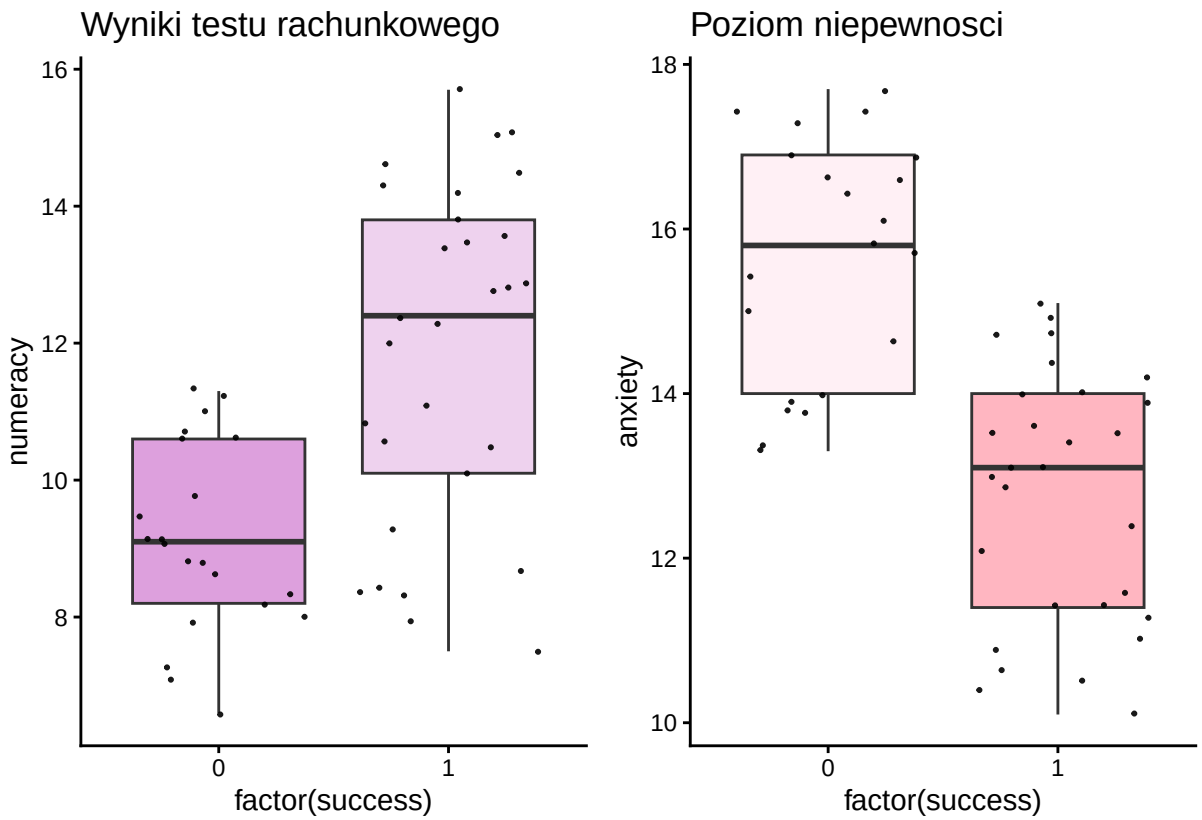

Wnioski

W oparciu o zamieszczony wykres `Wyniki testu rachunkowego w grupach: przyjęci vs nieprzyjęci` możemy wyciągnąć wniosek, jakoby wynik testu rachunkowego był w sposób znaczny skorelowany z decyzją o przyjęciu kandydata na studia, o czym świadczy, że każda z cech rozkładu, to znaczy wartości minimalne i maksymalne oraz kwartyle są mniejsze w przypadku grupy osób nieprzyjętych w porównaniu do osób przyjętych.

Wyższy wynik nie gwarantuje przyjęcia, ale daje większą szansę na to.

Porównując grupę nieprzyjętych i przyjętych osób na studia w zależności od rozkładu poziomu niepewności dochodzimy do konkluzji, iż ma on również silny wpływ na decyzję odnośnie przyjęcia. Grupa osób nieprzyjętych na studia cechuje się wyraźnie większymi odnotowaniami poziomów niepewności i każda cecha, tj. wartości minimalne i maksymalne oraz kwartyle, jest większa w porównaniu do wyników otrzymanych w grupie osób przyjętych.

4. Model regresji logistycznej

Konstrukcja modelu

Skontruujmy model regresji logistycznej oparty na danych pochodzących z pliku `Lista_1.csv`. W tym celu uzyjemy wbudowanej w `R` funkcji `glm`.

```r
model <- glm(success ~ numeracy + anxiety, data = dane, family = binomial(link = "logit"))
```

Estymatory parametrów i wyniki testów istotności

Przeprowadźmy testowanie parametrów w regresji logistycznej dla hipotez zerowych takich, że kolejne parametry są równe zeru na poziomie istotności $\alpha = 0.05$. Wyniki przechowuje tabela `Estymatory parametrów i poziomy istotności`.

Table 1: Estymatory parametrów i poziomy istotności

	Estymator parametru	p-wartość
β_0	14.238581	0.0362275
wynik testu rachunkowego	0.577352	0.0199523
poziom niepewności	-1.384069	0.0039634

Na poziomie istotności $\alpha = 0.05$ mamy podstawy do odrzucenia hipotezy zerowej w przypadku każdego z parametrów. Oznacza to, że każdy z nich możemy uznać za istotny.

Predykcja sukcesu dla danego poziomu niepewności i wyniku testu rachunkowego

```
##         1
## 0.8827987
```

Wymodelowane prawdopodobieństwo dostania się na studia ucznia o zadanym poziomie niepewności i wyniku testu rachunkowego wynosi w przybliżeniu 88%. Szansa na sukces jest więc wysoka.

Krzywa ROC

Naszkicujemy krzywą ROC, korzystając z funkcji wbudowanej w pakiet `pROC`.

a) logit

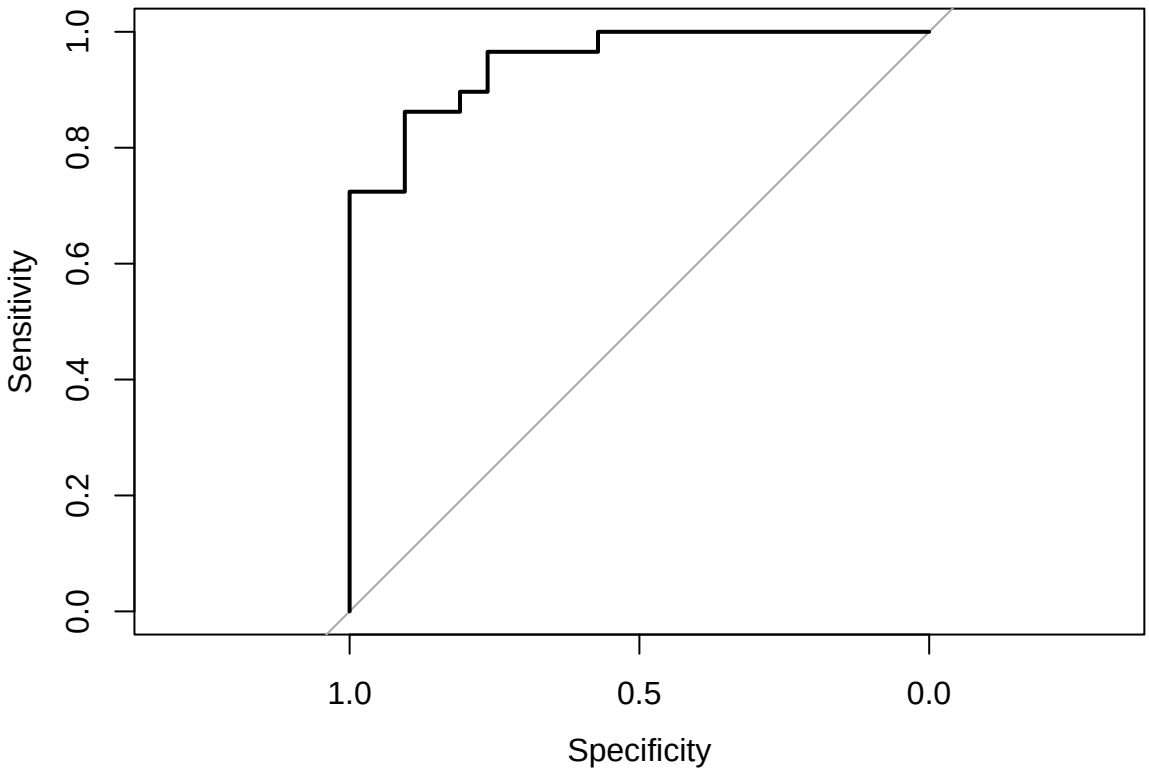


```
##
## Call:
## roc.default(response = dane$success, predictor = predict(model,     type = "response"), plot = TRUE)
##
## Data: predict(model, type = "response") in 21 controls (dane$success 0) < 29 cases (dane$success 1).
## Area under the curve: 0.9491
```

Istotnie odbiega ona od modelu liniowego, co świadczy o przewadze modelu regresji logistycznej.

a) probit

b) cauchit

c) cloglog

```
## Warning: glm.fit: dopasowane prawdopodobieństwa numerycznie okazały się być 0
## lub 1
```

Porównanie

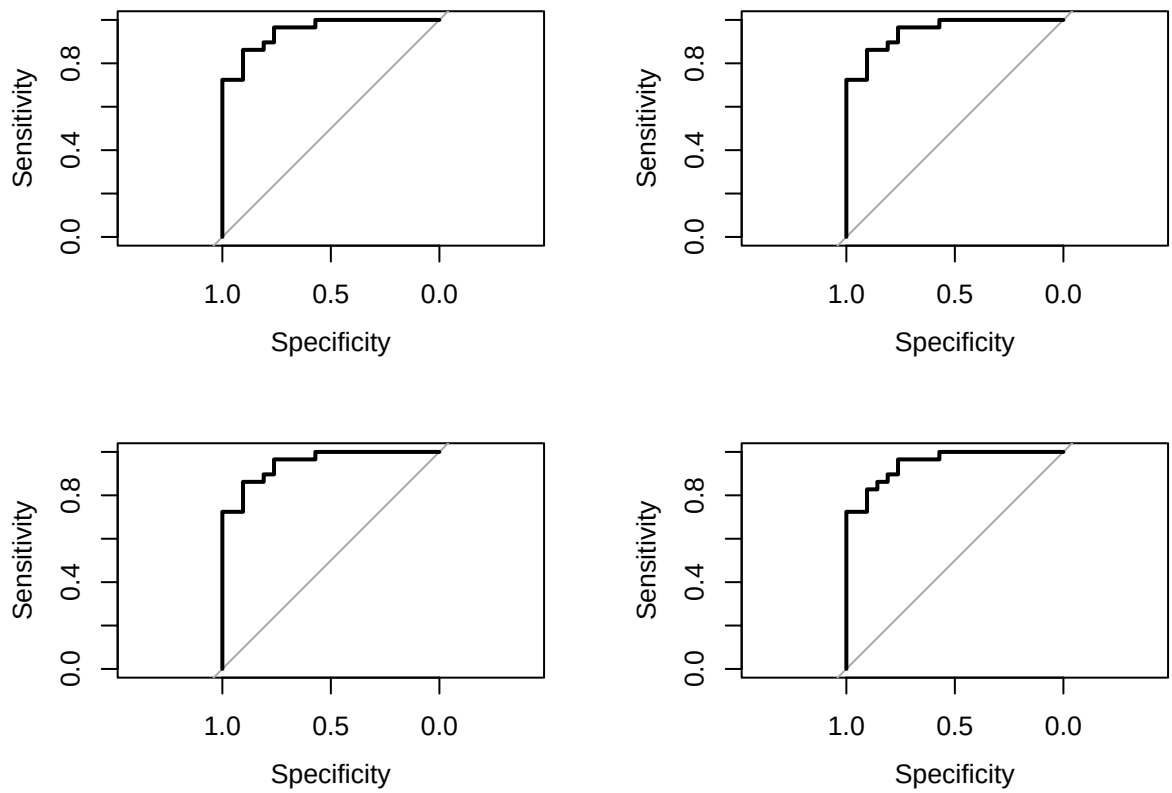


```
## [1] 1

## [1] 1

## [1] 0.4795001

## [1] 1

## [1] 0.4795001

## [1] 0.4795001
```

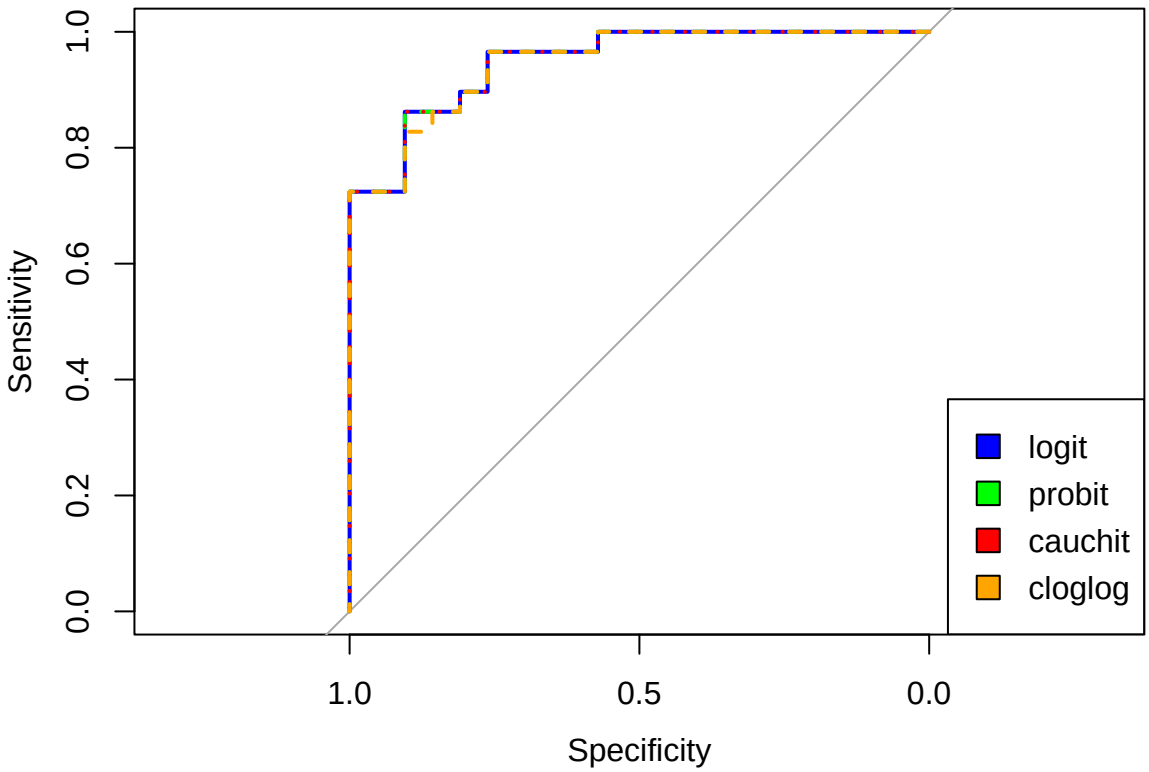

Mimo że wszystkie krzywe wyglądają identycznie, to często najlepszym wyborem jest stosowanie funkcji `logit` nie tylko ze względu na prostotę późniejszych obliczeń, ale też jej bliskość zarówno do rozkładu normalnego i fakt, że ogony nie są przesadzone jak w rozkładzie Cauchy'ego, ale i tak nie jest taki idealny jak normalny.

6. Model z funkcją linkującą "logit"

Estymator macierzy kowariancji

Wiemy, że estymator w regresji logistycznej jest asymptotycznie normalny, tzn. zachodzi

$$\hat{\beta} \xrightarrow{\mathrm{d}} \mathcal{N}(\beta, J^{-1}),$$

gdzie $J = -E_\beta HX'S(\beta)X$ jest tzw. macierzą informacji Fishera. Wyznaczymy $\hat{J}^{-1}$ korzystając z wbudowanej funkcji `vcov`.

```
X = vcov(model)
```

Otrzymany estymator ma w przybliżeniu postać:

$$\begin{pmatrix} 46.22 & -0.25 & -3.06 \\ -0.25 & 0.06 & -0.02 \\ -3.06 & -0.02 & 0.23 \end{pmatrix}$$

Porównanie

```
##                    vcov          r
## (Intercept) 46.21986333 46.21986333
## numeracy     0.06154567  0.06154567
## anxiety      0.23078671  0.23078671
```

Obie komendy dostarczają te same wyniki wariancji estymatorów.

Testowanie hipotezy // s.8 z wykładu 2

wersja pierwsza

Wykorzystamy test LRT (Likelihood Ratio Test) z hipotezą zerową $\mathrm{H}_0 : \beta_1 = \beta_2 = 0$

```
## Analysis of Deviance Table
##
## Model 1: success ~ 1
## Model 2: success ~ anxiety + numeracy
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1        49     68.029
## 2        47     28.286  2   39.744 2.343e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Na poziomie istotności $\alpha = 0.05$ mamy podstawy do odrzucenia hipotezy zerowej o braku wpływu regresorów poziomu niepewności i wyników testu rachunkowego na zmienną objaśnianą prawdopodobieństwa dostania się na studia.

wersja druga

W celu sprawdzenia czy zmienne objaśniające wpływają na zmienną odpowiedzi przetestowano hipotezę $\mathrm{H}_0 : \beta_1 = \beta_2 = 0$. Statystykę testową obliczono jako różnicę między null deviance i residual deviance:

$$\chi^2 = D(M_0) - D(M_1)$$

```r
summary(model)
```

```
##
## Call:
## glm(formula = success ~ numeracy + anxiety, family = binomial(link = "logit"),
##     data = dane)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)  14.2386     6.7985   2.094  0.03623 *
## numeracy      0.5774     0.2481   2.327  0.01995 *
## anxiety      -1.3841     0.4804  -2.881  0.00396 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
```

```
##     Null deviance: 68.029  on 49  degrees of freedom
## Residual deviance: 28.286  on 47  degrees of freedom
## AIC: 34.286
##
## Number of Fisher Scoring iterations: 6
```

```r
pchisq(68.029 - 28.286, df = 2, lower.tail = FALSE)
```

```
## [1] 2.343782e-09
```

Otrzymano $\chi^2 \approx 68.029 - 28.286 = 39.743$ przy $df = 2$, co daje p-wartość $p \approx 2.343782e^{-9}$. Na poziomie istotności $\alpha = 0.05$ mamy podstawy do odrzucenia hipotezy zerowej.

Wartość parametru epsilon

Regresja logistyczna jest estymowana iteracyjnie. W każdej iteracji obliczane są nowe wartości parametrów β. Algorytm zatrzymuje się, gdy zmiana jest bardzo mała:

$$|\beta^{(t+1)} - \beta^{(t)}| < \epsilon$$

Epsilon to właśnie ta wartość, od której mniejsza ma być różnica między kolejnymi przybliżeniami parametrów. Określa on dokładność zbieżności algorytmu.

Domyślnie w `R` wartość epsilon wynosi $\epsilon = 10^{-8}$.

```r
glm.control()$epsilon
```

```
## [1] 1e-08
```

Sprawdźmy własności modeli dla różnych wartości epsilona.

eps	iters	intercept	numeracy	anxiety
1e-01	3	12.89008	0.5375846	-1.263953
1e-02	4	14.09247	0.5735451	-1.371306
1e-03	5	14.23683	0.5773136	-1.383920
1e-06	6	14.23858	0.5773520	-1.384069
0e+00	6	14.23858	0.5773520	-1.384069

Symulacje